


Ejercicio

A partir de un conjunto de variables, se busca crear grupos de casos que compartan características comunes.



Fuente: <http://www.sthda.com/english/articles/tag/pam-clustering/>

Ejercicio



De la base de datos indicada, tome los primeros 4 clientes.

Por favor, idee una manera de decir qué clientes se parecen más entre sí, y cuáles difieren más entre sí.


Distancias



- Desafío de escogencia e importancia de variables (incluido correlaciones entre las variables).
- Desafío de métrica de distancia (incluye dimensiones y tipo de variables).

El Teorema del patito feo (Satosi Watanabe) (I)

- Clasificación es imposible sin sesgo.
- Dadas las innumerables características que se pueden seleccionar, dos entidades pueden ser arbitrariamente similares o diferentes.



Fuente: <http://37steps.com/4833/aristotle-ugly-duckling-theorem/>

Importancia de las variables



- Las variables pueden tener diferentes importancias.
- Las variables pueden estar correlacionadas (lo que genera pesos o importancias ocultas).
- Feature Engineering: usar conocimiento del contexto para crear variables útiles para la agrupación.

Eliminación de variables redundantes

Ataca dos problemas:

- Inestabilidad de la solución
- Pesos equivocados para las variables

Para eliminar variables redundantes:

- Por observación de correlaciones
- Uso de técnicas de reducción de datos (componentes principales)
- Decisiones de negocio



Espacio métrico

Conjunto de elementos con una noción de distancia entre ellos. Dicha distancia debe cumplir:

- $d(x,x)=0$
- Si x es diferente de y , $d(x,y)>0$
- $d(x,y)=d(y,x)$: Simetría
- $d(x,z) \leq d(x,y) + d(y,z)$: Desigualdad triangular.


Por ejemplo, la distancia dirigida (entre calles) no es una métrica pues no cumple la simetría. La distancia Euclídea (Pitágoras) sí es una métrica.

Data Understanding / Preparation

Métricas de distancias

Las métricas de distancia a escoger dependen de:

- La naturaleza de la(s) variable(s)
- La dimensionalidad del problema
- Los elementos a comparar



Data Understanding / Preparation

Métricas de distancias (Clustering)- Variables escalares

- **Distancia Euclídea (Norma L2):** Raíz cuadrada del cuadrado de la distancia




- Clásica. Más usada (intuitiva)

- **Distancia Manhattan (Norma L1):** Suma de los “catetos”



- Alta dimensionalidad

- **Distancia Coseno:** Complemento del coseno del ángulo entre vectores desde origen




- Texto. Vectores positivos
Importa más el “perfil” que la distancia

Data Understanding / Preparation


Métricas de distancias (Clustering)- Variables categóricas

- **Distancia Hamming:** Numero de diferencias.



- No tiene en cuenta dimensión. Si divido entre variables tengo el complemento del **matching coefficient**


- **Distancia Jaccard:** Complemento de: coincidencias (a) sobre total de coincidencias más diferencias (a+b+c). Al usar en vectores binarios, no tiene en cuenta los (0,0)



- Requiere ajuste cuando las coincidencias son pocas

• Gráficas: <https://towardsdatascience.com/9-distance-measures-in-data-science-918109d069fa>

- **Distancia Dice Index:** Complemento de:
• $2a$ sobre $2a+b+c$ para binarias, sin tener en cuenta (0,0)



Data Understanding / Preparation


Métricas de distancias (Clustering)- Variables escalares

- **Distancia Gower:** Primero se calcula la similitud Gower y se toma el complemento.
- **Similitud Gower:** Divide las variables en cuantitativas, categóricas y binarias (presencia/ausencia). En las cuantitativas, calcula la similitud Manhattan con estandarización 0-1; en las categóricas, el complemento de Hamming (coincidencias); y en binarias, las coincidencias (1,1) . Divide entre el número de cuantitativas más categóricas, más todas las binarias que no sean (0,0).

Data Understanding / Preparation

Métricas de distancias (Clustering)- Variables escalares

- **Distancia Mahalanobis:** Distancia euclídea multiplicada por la inversa de la matriz de covarianzas. Básicamente es la distancia euclídea en un sistema diferente de coordenadas (componentes principales estandarizados)
- Ventajas: tiene en cuenta la correlación de las variables. Útil para outliers
- Dificultades: Alta dimensionalidad/volumen. Altísima correlación.



Fuente:

https://www.researchgate.net/publication/336760197_Monitoring_of_a_machining_process_using_kernel_principal_component_analysis_and_kernel_density_estimation/figures?lo=1

Data Understanding / Preparation

Normalización y estandarización

Ataca dos problemas:

- Diferentes dimensiones (unidades de las variables).
- Influencia de valores extremos en los clúster.

Para volver más simétrica:

Uso de transformaciones. Las más usadas: logaritmo natural, en base 10 y raíz cuadrada.

Para estandarizar:

Estandarización z o estandarización de mínimos/máximos.

Ejercicio


El profesor calculará métricas de distancia en la base de datos seleccionada.

Los estudiantes recogerán sus datos personales y calcularán la distancia entre ellos.

Referencias

(Clustering)

- Aggarwal, Hinneburg & Keim (2001) *On the surprising behavior of distance metrics in high dimensional space*. International Conference on Database Theory.
- <https://stats.stackexchange.com/questions/166525/is-mahalanobis-distance-equivalent-to-the-euclidean-one-on-the-pca-rotated-data>



Aplicación 1: clustering


Crear grupos de casos cercanos dentro del grupo pero lejanos a otros grupos

- Objetivo: Minimizar la suma de las distancias intracluster
- Un problema fundamental es definir el número de K clústeres
- Asignar N puntos a K clústeres es un problema NP-Hard

Cluster jerárquico

Métodos basados en optimización combinatoria: **Clustering Jerárquico**


- A partir de la matriz de distancia entre los casos, se van agregando los dos “casos” más cercanos.
- Grupos de casos se vuelven nuevos “casos”. Su distancia con los demás puntos debe definirse detalladamente



Fuente: Hastie et al. (2015). The Elements of Statistical Learning. Fig 14.13

Modelación

Métodos basados en optimización combinatoria: **Clustering Jerárquico**



Simple Linkage $\Rightarrow$ B - C
Complete Linkage $\Rightarrow$ A - B

Ejercicio

Hacer (entre todos) un clúster jerárquico paso a paso para “agrupar” a los estudiantes del curso

Revisar notebook de cluster jerárquico.

Aplicación 2: Recomendaciones

Buscar casos cercanos para hacer recomendaciones

- Objetivo: Predecir una “recomendación”
- La representación es fundamental.

Ejercicio

En el archivo “cosmeticspan.xlsx” están los consumos de cosméticos de un grupo de clientes. Detectar el cliente más cercano para hacerle una recomendación.

Buscar y calcular la distancia entre películas

Ejercicios para desarrollar en casa

Revisar si es una métrica:

- X-Y (como vectores)
- $d_i = \frac{|X-Y|}{1+|X-Y|}$

Ejercicios para desarrollar en casa

Se le pidió a chatgpt la creación de una función que calculara la distancia de Gower. Se adjunta el resultado. Indicar si el resultado obtenido por chatgpt es correcto; si lo es, buscar hacer precisiones o mejoras a la función; si no lo es, realizar las correcciones adecuadas.

- <https://chatgpt.com/share/679bb449-00c4-8000-b3d4-8197d48977fe>

