

Cálculo de vecinos más cercanos según métricas de distancia Amaya

Sergio

1. Datos:

Hay 35 Variables disponibles en el archivo.

- Se identifico 4 tipos de variables: Metadatos de la encuesta: los cuales correspondian Id informacion cuando se objetivo la respuesta; Numericas ordinales: variables correspondientes a gustos musicales(van de 1-5); Numericas continuas: variables de ya sean en horas, minutos o seguidores y categoricas: bebida preferida, genero y medio de transporte
- Eleccion de variables: Primero vamos a eliminar las columnas que no aportan nada que corresponden a los metadatos de la encuesta: "ID", "[Hora.de.inicio](#)", "[Hora.de.finalización](#)", "Correo.electrónico", "Nombre" y "[Hora.de.la.última.modificación](#)".
- Exploracion de los datos: se encontro que habia un registro nulo, el cual se lleno con la mediana, ya que este correspondia a una variable numeica ordinal de gusto por la electronica, ademas se encontro registros como **Tiempo de transporte de la casa a la Universidad** que registraban horas en unidades flotantes y cuando la gran mayoría se registro en minutos y un registro en **Horas de sueño promedio la última semana**, que tenia la suma de las horas totales de la semana y no el promedio.

2. Eleccion de metodo de distancia:

Dado que hay variables numericas y categoricas, se escogio el metodo de Grower dado que es mixto, sin embargo se realizara una comparacion de diferentes elecciones para las variables: 1. base todas las variables, 2 Feature seleccion por correlacion(se combinan las variables con mayor correlacion) y 3 Componentes principales.

- Se encontro una alta correlacion entre gusto por musica flamenco y musica tango, algo esperable, por otro lado la correlacion encontrada entre paises visitados y gusto por el rock, esta interesante.

```
> print(cor_melt)
      Var1
10  X.qué.tanto.le.gusta.la.música.tango.
161 Número.de.países.visitados
208 X.qué.tanto.le.gusta.la.música.flamenca.
513 X.qué.tanto.le.gusta.la.música.rock.
      Var2      value
10 X.qué.tanto.le.gusta.la.música.flamenca. 0.8249424
161 X.qué.tanto.le.gusta.la.música.rock. 0.8177326
208 X.qué.tanto.le.gusta.la.música.tango. 0.8249424
513 Número.de.países.visitados 0.8177326
```

- Se realizó PCA y el criterio de eleccion de componentes fue que representaran al menos 80% de la varianza, por lo tanto se escogen 5 componentes

```
> summary(pca)
Importance of components:
      PC1      PC2      PC3      PC4      PC5      PC6      PC7
Standard deviation  2.6381  1.9397  1.7820  1.6585  1.38264  1.10660  1.03293
Proportion of Variance 0.3026  0.1636  0.1381  0.1196  0.08312  0.05324  0.04639
Cumulative Proportion 0.3026  0.4662  0.6042  0.7238  0.80696  0.86021  0.90659
      PC8      PC9      PC10     PC11     PC12     PC13     PC14
Standard deviation  0.8082  0.78382  0.62606  0.51849  0.34554  0.31721  7.456e-16
Proportion of Variance 0.0284  0.02671  0.01704  0.01169  0.00519  0.00437  0.000e+00
Cumulative Proportion 0.9350  0.96170  0.97875  0.99043  0.99563  1.00000  1.000e+00
```

3. Resultados:

metodo/vecino	Vecino 1	Distancia 1	Vecino 2	Distancia 2
Grower	NA	0.2246691	Steven Peinado	0.2397373
Grower correlaciones	Steven Peinado	0.2736043	NA	0.2850582
Grower PCA	Steven Peinado	0.1751036	NA	0.2058037

La unica diferencia evidente es que a comparacion de aplicar Grower sin feature engineering, cuando este se da, el orden del vecino mas cercano se intercambia, pero siguen siendo los mismos registros de Steven Peinado y NA que en la tabla original es el registro 1.