




Regresión




Regresión Lineal

$$Y = b + mx$$

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$



Regresión Lineal



- El promedio de la variable dependiente (Y) bajo la condición de un valor de la variable independiente (X)- Factor explicativo
- El mejor ajuste de los datos a una recta-factor predictivo

Interpretación de los Coeficientes de la Regresión Lineal



- El coeficiente es el grado en que varía la variable dependiente (Y) por cada unidad de la variable independiente (X)- Razón de cambio
- El coeficiente es el de mejor ajuste a los datos o el resultado de Y (dependiente) cuando X es cero (independiente)

Análisis de Varianza

Es una prueba de hipótesis con:

H_0 : Las variables son independientes

H_1 : Las variables están asociadas

Una alternativa más precisa de interpretación es:

H_0 : Las variables independientes explican tanto como el azar (error aleatorio)

H_1 : Las variables independientes explican más que el azar (error aleatorio)


Prueba de Hipótesis para los parámetros

Esta prueba examina cada una de las variables independientes e indica si tienen o no significado en el modelo

H_0 : La variable no tiene significado o no está asociada ($B=0$)

H_1 : La variable tiene significado y está asociada ($B \neq 0$)

Calidad de la Regresión Lineal (Métricas básicas de pérdida)



Suposiciones y Diagnósticos (Simples)

- 01 Normalidad de los residuos con media cero:** prueba de normalidad-estadísticos de residuo
- 02 No autocorrelación de residuos:** prueba Durbin-Watson. Regla práctica: $d > 1.8$
- 03 Homoscedasticidad:** Gráfico de predicciones (estándar) vs. residuos estándar
- 04 Especificación de variables independientes:** significancia y signo de los parámetros
- 05 Puntos influyentes:** Outliers, diagnósticos de influencia



Tamaño de Muestra




- Lo mejor es tener más de una medición por valor de la(s) variable(s) independiente(s) y garantizar la mayor cobertura posible de la misma en rango.
- **Radios empíricos:** 10 a 15 datos por variable independiente (Harrell); 5 mínimo, 20 recomendado (Hair); 50 a 1 si se hace stepwise.

Regresiones (Feature Selection)



Métodos de selección de variables en Regresión Múltiple




Entrenamiento y Validación



En cualquiera de los casos anteriores, es buena práctica someter los modelos obtenidos a un proceso de entrenamiento y validación (partición, validación cruzada, etc.)

Suposiciones y Diagnósticos de Modelamiento (Múltiples)



Calidad de la Regresión Lineal (Métricas penalizadas de pérdida)



- **AIC:** Basado en teoría de la información. Penaliza por parámetros
- **BIC:** Basado en teoría de la información. Penaliza por parámetros y ajusta por tamaño de muestra.
- **R² ajustado:** Penaliza por el número de parámetros (a través de los grados de libertad)

Calidad de la Regresión Lineal (AIC)

Es una primera “idea” de regularización. La idea es penalizar por la cantidad de parámetros (en este caso, cada variable es un parámetro) de forma que haya un aumento en la “función objetivo” (en este caso, aumentar la probabilidad de los datos /dado el modelo).

$AIC = 2k - 2 \ln(L)$, donde k es número de parámetros.

Es diferente para cada tipo de modelo pues cada modelo tiene su función de verosimilitud.

- AIC es relativo entre modelos
- Es mejor mientras más pequeño es

Modelo Preespecificado



Se supone que el modelo fue predefinido de antemano, no debió haber sido visto con exploración previa.

Fuertemente basado en la teoría.

Método Stepwise

Hace pruebas de hipótesis parciales:

- ¿Dado el modelo actual de regresión, vale la pena incluir alguna variable? (Hacia adelante)
- ¿Dado el modelo actual de regresión, vale la pena excluir alguna variable? (Hacia atrás)




Best Subsets

- Detecta el mejor modelo de cada posible tamaño k entre p predictores ($k < p$).
- **Escogencia del k final:** un punto de corte en el error
- Por origen usa una métrica llamada C_p de Mallows (de penalización) conectada con AIC
- Da poder de decisión al modelador

Regresión por Componentes Principales

Realizar análisis factorial/componentes principales y usar dichos componentes como predictores.

Ayuda a reducir la complejidad del modelo y elimina la multicolinealidad.




Regresión Polinomial y Transformaciones




Regresión Lineal Polinomial


Modelo Cúbico




Modelo Inverso




Modelo Logarítmico




Modelo de Potencia




Modelo Compuesto




Modelo Curva - S



Modelo de Crecimiento



Modelo Exponencial



Ideas Fundamentales

Ventajas

- Hacer transformaciones linealizables
- Incluir grados polinomiales que puedan dar mejor ajuste
- Coordinación con modelo preespecificado

Desventajas


- Riesgo de overfitting
- Basta con un polinomio grado 3 para la mayoría de los casos
- Dificulta la comprensión/explicación

Transformación Inversa

- Hay una importante reducción en los extremos
- Los casos con implicaciones fisicoquímicas suelen tener este tipo de relación

Transformación Logarítmica

- Puede detectarse con los residuos vs. predicciones
- Es necesario preguntarse si tiene sentido en el negocio



Logaritmos en la Empresa


- El aumento de una variable X no siempre genera el mismo aumento en la Y
- El clásico ejemplo es la satisfacción (o el rendimiento) en función de la cantidad de un satisfactor (insumo)
- Esto se conoce como la ley de los rendimientos marginales decrecientes y puede modelarse con un logaritmo

Curvas de Ingreso

- El ingreso es función de la demanda y el precio
- Sin embargo, usualmente la demanda es función del precio
- Ello genera “naturalmente” un polinomio de grado 2

Polinomio grado 2

- Genera una función convexa con un único punto crítico
- De acuerdo al dominio del conocimiento
- Puede detectarse con los residuos vs. la variable



Polinomio grado 3

- Puede modelar diversos puntos críticos o de inflexión
- Es la de mayor riesgo de overfitting


Polinomios

- El grado 3 suele ser suficiente
- Existe riesgo de multicolinealidad. **Solución:** polinomios ortogonales.

Métodos de Encogimiento (Ridge + Lasso)



El Problema del Sobreajuste (Overfitting)



- **Por principio científico:** La navaja de Occham
- **Por principio de validación:** pobre desempeño en datos nuevos
- **Por principio práctico:** capacidad de explicación e implementación

Fuente: <https://en.wikipedia.org/wiki/Overfitting>

El Balance Sesgo-Varianza (matemáticamente)

$$E(MSE) = \sigma_t^2 + (\theta - E(t))^2 + \sigma_\varepsilon^2$$

Diagram illustrating the components of the Mean Squared Error (MSE) decomposition:


- σ_t^2 : Los errores (cuadrados) a largo plazo
- $(\theta - E(t))^2$: Variabilidad del estimador
- σ_ε^2 : Sesgo (cuadrado)
- Varianza "error irreducible" (pointing to σ_ε^2)

t =Estimación de $f(x)$; $q = f(x)$

El Balance Sesgo-Varianza (en palabras)

- La fuente del sesgo es la incorrección del modelo (ajuste pobre)
- La fuente de la varianza del estimador es la modelación del ruido (sobreajuste)
- El mejor modelo es aquel que logra minimizar la suma de ambas fuentes de error

El Balance Sesgo-Varianza (en imagen)



Fuente: Hastie et al. (2009) The elements of statistical learning, p.38



Regularización

Realizar una optimización tal que la función de pérdida es penalizada basada en la complejidad del modelo, usando un parámetro lambda.

$$\textit{Funcion objetivo} = \min \sum_{i=1}^n f(y_i, \hat{y}_i) + \lambda * R(f)$$

No hay un criterio único para escoger lambda.

La regularización es generalizable a otros modelos (p.e., SVM o ensambles)

Ridge Regression

Basada en el principio de **regularización**: la penalización es la norma 2 al cuadrado de los coeficientes.

$$\textit{Funcion objetivo} = \min \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda * \sum_{j=1}^p \beta^2$$

Hiperparámetro

- **Lambda:** A mayor valor, mayor el sesgo y menores los parámetros
- **Preparación:** estandarización
- **Ventaja:** Multicolinealidad
- Intercepto está fuera de la optimización

Lasso

Basada en el principio de **regularización**: la penalización es la norma el valor absoluto de los coeficientes.

$$\textit{Funcion objetivo} = \min \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda * \sum_{j=1}^p |\beta|$$

Detalles

- **Lambda:** A mayor valor, mayor el sesgo y menores los parámetros. Particularmente, si es mayor que la suma de los estimadores OLS, Lasso no hace nada. Si lambda es más o menos el 50% de dichos estimadores, reduce en un 50% en promedio los estimadores (no es lineal, sin embargo)
- Mayor tendencia a obtener ceros

Redes Elásticas (Elastic Nets)

Busca un equilibrio entre Lasso y Ridge, y tiene facilidades computacionales.

$$\textit{Funcion objetivo} = \min \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda * \sum_{j=1}^p (\alpha |\beta_j| + (1 - \alpha) \beta_j^2)$$

Validación Clásica

Usualmente la división de una base de datos en Machine Learning se hace en 3 partes:

- **Entrenamiento:** Para que los modelos aprendan
- **Validación:** Para probar los modelos y seleccionar el mejor
- **Prueba:** Para estimar el error en datos frescos del modelo seleccionado

Validación Cruzada

Con pocos datos, se utiliza validación cruzada:

- Se divide en k partes la base.
- Iterativamente se usan $k-1$ partes para entrenar, y 1 parte para medir el error
- Se promedian los errores de las k particiones para estimar el error y seleccionar el modelo.