



Regresión Logística



Regresión Logística

A partir de un conjunto de variables escalares (o dummies) se busca predecir una respuesta tipo binomial

- ¿Qué tan probable es que se acepte una oferta?
- ¿Puedo acercarme a la predicción de una falla?



Modelo de Regresión Logística



$$Prob(Y = 1) = \frac{1}{1 + e^{-(\alpha + \beta_1 * x_1 + \beta_2 * x_2 + \dots + \beta_k * x_k)}}$$

Modelo de Regresión Logística

La regresión logística minimiza el promedio de la pérdida logarítmica (logística) también como entropía cruzada. Para el caso de la regresión logística, si se tiene un verdadero valor Y y una probabilidad de estimación $p(y_i)$ se calcula:

$$H_p(q) = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(p(y_i)) + (1 - y_i) \cdot \log(1 - p(y_i))$$

Ejemplo: 5 clientes, sus decisiones de compra Y , sus probabilidades de compra p según un modelo, y sus valores de pérdida respectivo. El promedio de esas pérdidas es el log-loss

Cliente	Real y	Prob. compra p	Término que usamos	Pérdida 
1	1	0.8	$-\ln(0.8)$	0.2231
2	1	0.9	$-\ln(0.9)$	0.1054
3	1	0.3	$-\ln(0.3)$	1.2040
4	0	0.6	$-\ln(1 - 0.6) = -\ln(0.4)$	0.9163
5	0	0.1	$-\ln(1 - 0.1) = -\ln(0.9)$	0.1054

Odds

- Odd (ejemplo 1): Las apuestas están 4:1- Odd es 4
- Odd (ejemplo 2): Probabilidad de compra: 0.6

$$Odd = \frac{0.6}{0.4} = 1.5$$

Odd Ratio

Aumento porcentual del Odd



Si Odd ratio > 1 : Se incrementa la probabilidad de lo que se definió como objetivo



Si Odd ratio < 1 : Se disminuye la probabilidad de lo que se definió como objetivo



Odd Ratio

Ejemplo 1

Odd ratio=2, con Odd de 1.5 significa que la probabilidad aumentó de 60% a 75%.

$$Odd1 = \frac{0.6}{0.4} = 1.5$$

$$Odd2 = \frac{0.75}{0.25} = 3$$

Odd Ratio

Ejemplo 2

Odd ratio=2.25, pero Odd inicial de 0.11 significa que la probabilidad aumentó de 10% a 20%.

$$Odd1 = \frac{0.1}{0.9} = 0.11$$

$$Odd2 = \frac{0.2}{0.8} = 0.25$$

Luego, el Odd ratio debe ser interpretado sobre la probabilidad base

Interpretación de efectos en la Regresión Logística

- Un coeficiente mayor que 0 indica una propensión a pertenecer al grupo de resultados “**positivos**”
- Un coeficiente menor que 0 indica propensión hacia los “**negativos**”
- Una exponencial entre 0 y 1 significa propensión al resultado “**negativo**” (Odd ratios)
- Una exponencial mayor que 1 significa propensión al resultado “**positivo**” (Odd ratios)

Calidad – Prueba de Hipótesis para los parámetros

Esta prueba examina cada una de las variables independientes e indica si tienen o no significado en el modelo

H_0 : La variable no tiene significado o no está asociada ($B=0$)

H_1 : La variable tiene significado y está asociada ($B \neq 0$)

Suposiciones

Las variables deben ser en lo posible escalares, pero se pueden incluir dummies y ordinales

Medición sin error y representativo



Métricas de Evaluación en Clasificación

Validación



Métricas de Clasificación




Matriz de Confusión

Observado	Pronosticado		Pronosticado
	Si	No	% correcto
Si	140	60	70%
No	20	80	80%
Global	53.3%	46.7%	73.3%

Fallo

Acierto

Matriz de Confusión



Precisión y Exhaustividad

- **Precisión / Especificidad (precision):** Verdaderos positivos de todas las predicciones positivas
- **Exhaustividad / Sensibilidad (recall):** Verdaderos Positivos de todos los que son realmente positivos
- Dado un modelo, se presenta un **balance** entre precisión y exhaustividad: Al cambiar el punto de corte, la una aumenta mientras la otra disminuye

Precisión y Exhaustividad

Observado	Pronosticado	Pronosticado	Pronosticado
	Si	No	% correcto
Si	140	60	70%
No	20	80	80%
Global	53.3%	46.7%	73.3%

Verdaderos positivos (TP)

Falso positivo (FP)

Falso negativo (FN)

Verdaderos negativos (TN)

$$Precision = \frac{TP}{TP + FP} = \frac{140}{140 + 20} = 87.5\%$$

$$Exhaustividad = \frac{TP}{TP + FN} = \frac{140}{140 + 60} = 70\%$$




Precisión y Exhaustividad


- Dado un modelo, se presenta un **balance** entre precisión y exhaustividad: Al cambiar el punto de corte, la una aumenta mientras la otra disminuye

Corte=0.1
Alta exhaustividad
(verde vs azul)


Baja precisión
(verde vs rojo)



Corte=0.25
"óptimo" para
F score




Corte=0.5
Corte por defecto



Corte=0.8
Baja exhaustividad
(verde vs azul)

Alta precisión
(verde vs rojo)



F-Score

Media Armónica de precisión y exhaustividad

$$F - Score = 2 * \frac{precisión * exhaustividad}{precisión + exhaustividad} = 77.7\%$$


Overall Error Rate

Total de falsos positivos y falsos negativos dentro de las predicciones hechas.

$$OER = \frac{FP + FN}{FP + FN + TP + TN} = 26.7\%$$


Curva COR

- **Sensibilidad:** Capacidad de detectar correctamente el grupo objetivo (potencia)
- **1- Especificidad:** Clasificar incorrectamente como del grupo objetivo a quien no lo era (error tipo I)



Lift Chart

- **Eje X:** Porcentaje de la base de datos
- **Eje Y:** Porcentaje de éxitos (TP)



Fuente: Cooldata.wordpress.com

KPI: Ganancia Neta

Es demostrable que la ganancia neta de un modelo de predicción binaria está dada por:

$$B * E * (\$I - \frac{\$C}{P})$$

B = Número total de posibles éxitos

E = Exhaustividad

P = Precisión

\$I = Ingreso por el éxito (descontando otros costos que no sean de contacto)

\$C = Costo (o ganancia perdida) por el fracaso

KPI: Ganancia Neta

De la anterior ecuación se puede deducir que para obtener una ganancia neta es necesario y suficiente que:

$$P > \frac{\$C}{\$I}$$

- Aumentar la exhaustividad (con la precisión constante) implica ampliar el volumen de éxitos
- Aumentar la precisión (con exhaustividad constante) implica lograr una ganancia marginal mayor por reducción de costos
- En algunos casos no se necesita un modelo porque la precisión requerida es muy baja dado el costo/beneficio
- La evaluación de costos/beneficios con frecuencia no tiene en cuenta el tiempo (Customer lifetime value) o un posible crecimiento en portafolio de productos

Regresión Logística y Temas Previos

Para mejorar un proceso de regresión logística se puede pensar en:

- **Feature Selection:** otros métodos para seleccionar las variables
- **Feature Engineering:** Hay posibilidad de relaciones no lineales? Interacciones? Otras variables?
- **Regularización:** Efectivamente se puede aplicar Redes elásticas, Lasso o Ridge

Datos Desbalanceados

Ejercicio

You are given 12 balls, all equal in weight except for one that is either heavier or lighter. You are also given a two-pan balance to use. In each use of the balance you may put any number of the 12 balls on the leftpan, and the same number on the right pan, and push a button to initiate the weighing; there are three possible outcomes: either the weights are equal, or the balls on the left are heavier, or the balls on the left are lighter. Your task is to design a strategy to determine which is the odd ball and whether it is heavier or lighter than the others in as few uses of the balance as possible.




Figure 4.2. An optimal solution to the weighing problem. At each step there are two boxes: the left box shows which hypotheses are still possible; the right box shows the balls involved in the next weighing. The 24 hypotheses are written $1^+, \dots, 12^-$, with, e.g., 1^+ denoting that 1 is the odd ball and it is heavy. Weighings are written by listing the names of the balls on the two pans, separated by a line; for example, in the first weighing, balls 1, 2, 3, and 4 are put on the left-hand side and 5, 6, 7, and 8 on the right. In each triplet of arrows the upper arrow leads to the situation when the left side is heavier, the middle arrow to the situation when the right side is heavier, and the lower arrow to the situation when the outcome is balanced. The three points labelled $\star$ correspond to impossible outcomes.

MacKay, David (2003) Information Theory, Inference, and Learning Algorithms. Ej 4.1, p. 66

Datos Desbalanceados

Se dice que los datos están desbalanceados si la clase a predecir tiene un bajo porcentaje dentro de los datos ($< 10\%$). La clase a predecir es entonces la menor, y la clase con más casos es la mayor.



Dificultades

Aprendizaje de la clase mayor

Sobreposición de datos

Densidad: falta de datos para combinaciones de variables

Cambio en el dataset con el tiempo o en test set

Datos de ruido (errores) y de borde (el azar los cambia de lado)

Casos pequeños disyuntos: pequeños grupos de casos ubicados en el lugar “incorrecto”

¿Por qué balancear?

- Teoría del aprendizaje
- Teoría de la información: óptima distribución de casos de aprendizaje




¿Cómo balancear?

- **Undersampling:** El riesgo es la pérdida de datos
- **Oversampling:** El riesgo es overfitting
- **Under or Over mejorado:** Trata de superar las dificultades dadas por estos iniciales

CNN (Under)


- Crear una base entrenamiento E con todos los de la clase menor y uno de la clase mayor
- Aplicar un modelo KNN ($k=1$) para la base original O basada en el entrenamiento E
- Mover los casos mal clasificados a E



Fuente: Herrera (2013) Imbalanced classification: Common approaches and open problems. 2013 International School on Trends in Computing

Tomek Link (Under)

- Remueve ruido y casos extremos así:
- Toma todas las parejas i, j de clases diferentes (i la clase mayor, j la menor)
- Remueve el elemento i de un Tomek Link, donde el link es una pareja cuya distancia es menor entre ellos que a cualquier otro punto



Herrera (2013) Imbalanced classification: Common approaches and open problems. 2013 International School on Trends in Computing

NCL (Under)

- Para ejemplos de la clase mayor, si está rodeado de k ejemplos de la clase menor, remuévalo.
- Para ejemplos de la clase menor, si está rodeado de k ejemplos de la clase mayor, remueva los k ejemplos de la clase mayor

ENN (Under)

Remueve ejemplos cuya clase (menor o mayor) difiere de dos de sus k vecinos más cercanos


Smote (Over)

Crea ejemplos de la clase menor interpolando entre ejemplos de la clase menor que están juntos (como vecinos más cercanos).

Selecciona k vecinos de la misma clase menor de un ejemplo y selecciona al azar j de estos ejemplos.

Crea ejemplos en las líneas que unen el ejemplo inicial con los nuevos ejemplos.

Smote (Over)




Herrera (2013) Imbalanced classification: Common approaches and open problems. 2013 International School on Trends in Computing

Híbridos Clásicos

- Smote + Tomek
- Smote + ENN
- CNN+ Tomek = OSS

Recomendaciones



Recuerde: Se está cambiando la estructura de los datos

No es claro a priori qué estrategia es mejor



Matrices de Costos

Definir una matriz de costos de clasificación errónea

“Pesar” los casos de acuerdo a los costos:

- a. Tradicional = oversampling
- b. Usar el Teorema de Bayes para asignar al menor riesgo
- c. Cambiar el algoritmo para entrenar costos